Appunti SLIDE INTRODUZIONE DEI COMPILATORI

Processamento dei linguaggi: Preparare un programma per far sì che sia eseguibile su un computer. Assicura che il programma conformi con la semantica intesa.
Traduce in una forma più facilmente eseguibile da computer. I due estremi sono:
1)Interprete, gira il programma esaminando la struttura dei costrutti e simulandone le azioni.
2)Compilatore, traduce il programma in istruzioni macchina eseguibili direttamente nel computer.

Linguaggio macchina puro: Codice per un particolare set di istruzioni macchina non assumendo l'esistenza di alcun sistema operativo o libreria di funzioni**.** Questo approccio è molto raro, relegato a linguaggi per implementazione di sistemi operativi o applicazioni "embedded".

Linguaggio macchina "augmented": I compilatori generano codice per un particolare set di istruzioni macchina arricchito con routine di sistema operativo o di supporto (I/O, allocazione di memoria), che vanno linkate al codice oggetto.

Assembler: Viene prodotto un file di testo contenente il codice sorgente assembler. Un certo numero di decisioni nella generazione del codice (target delle istruzioni di salto, forma degli indirizzi) sono lasciate all'assemblatore.
Molte volte il C è usato come assembler. Il C viene chiamato linguaggio assembler universale, per il fatto che è relativamente a basso livello, ma anche indipendente dalla piattaforma.

Codice per una Macchina Virtuale: Permette di generare codice eseguibile indipendente dall'hardware. Se la macchina virtuale è semplice, il suo interprete può essere facile da scrivere.
Questo approccio penalizza la velocità di esecuzione di un fattore da 3:1 a 10:1.
Esiste la compilazione **"Just in Time" (JIT)** che può tradurre porzioni di codice virtuale in codice nativo. Il JJT rappresenta una modalità di compilazione di tipo dinamico che consente di migliorare le prestazioni di linguaggi di programmazione che usano il bytecode.
Vantaggi:

1)Semplificare un compilatore fornendo le primitive adatte (ad esempio come chiamate di metodo, manipolazione di stringhe).
2)Diminuzione della dimensione del codice generato se le istruzioni sono progettate per una particolare linguaggio di programmazione (per esempio codice JVM per Java)
3)Trasportabilità del compilatore ovvero la portabilità del mio codice.
4)Possibilità di verificare che il codice non contenga istruzioni "maliziose"

TRADUZIONE DIRETTA DALLA SINTASSI

Sarebbe difficile progettare un algoritmo di traduzione di un linguaggio complesso senza prima analizzare la frase sorgente nei suoi costituenti definiti dalla sintassi.
L'analisi sintattica riduce la complessità del problema del calcolo della traduzione, decomponendo il problema in sotto-problemi più semplici.
(In modo simile l'analisi lessicale riduce la complessità dell'analisi sintattica.)
Per ogni costituente della frase sorgente il traduttore esegue le azioni appropriate per preparare la traduzione, azioni che consistono nel raccogliere informazioni sui nomi (nella tabella dei simboli), nel fare dei controlli semantici, ecc.
Il lavoro del traduttore è modularizzato secondo la struttura descritta dall'albero sintattico della frase.
La traduzione diretta dalla sintassi è diretta da produzioni.
Questo tipo di traduttori è detto guidato dalla sintassi.

APPROCCI ALLA TRADUZIONE

1)approccio in due fasi:

1.1) Il parser sintetizza **l'Abstract Syntax Tree (AST**), che è un albero di parsing in forma astratta nella fase di analisi sintattica.

1.2) Si utilizza l'AST per l'analisi semantica e poi per la sintesi dell'output.

2)approccio semplificato una fase:

→ Si sintetizza l'output (ovvero genero il mio codice) direttamente durante l'analisi sintattica, senza costruire l'AST.

Nel primo caso si ha a disposizione l'AST per fare analisi semantica ed elaborazione dell'output (si possono fare diverse passate sull'AST).

Nel secondo caso non si memorizza l'albero, ma si è legati a come si fa il parsing (se top-down) o bottom-up. Non si ha a disposizione tutto l'albero per cui si possono fare SOLO elaborazioni semplici.

Il parse tree è l'albero corrispondente alla derivazione di una stringa della grammatica: il parse tree contiene tutti i dettagli del parsing (cioè i nodi per tutti i simboli usati nella derivazione).

L'AST è definito per rendere possibile l'analisi semantica e la traduzione ed è una astrazione del parse tree (ha molti meno nodi!).

Grammatica di un semplice linguaggio di programmazione

```
Start   → Stm $
Stmt    → id assign E
        | if lparen E rparen Stmt else Stmt fi
        | while lparen E rparen Stmt od
        | { StmLs }
Stmts   Stmts ; Stmt
        | Stmt
E       → E plus T
        → E minus T
        | T
T       → id
        | intNum
        | floatNum
```

Dove in blu sono i token (i terminali della grammatica). Per esempio `lparen` token per "(", `rparen` token per ")", `assign` token per "=", `plus` token per "+ " e `minus` token per "- ", ecc..

Manca una t alla Start → Stmt $

Linguaggio a parentesi bilanciate.

NODI DI ABS PER IL LINGUAGGIO

Sintetizzano l'informazione derivata dal parsing. Alcuni alberi standard per costrutti di linguaggi.

1) if, 2) while, 3) assegnamento, 4) operatori binari, 5) blocco

STRUTTURA DI UN COMPILATORE

Ci sono due fasi fondamentali in un compilatore:

Analisi: viene creata una rappresentazione intermedia del programma sorgente.

1)Analisi Lessicale è il processo che prende in ingresso una sequenza di caratteri e produce in uscita una sequenza di token.

2)Analisi Sintattica (o parsing) è un processo che analizza un flusso continuo di dati in ingresso in modo da determinare la correttezza della sua struttura grazie ad una data grammatica formale. Un parser è un programma che esegue questo compito.

3)Analisi Semantica

Sintesi: viene creato, partendo dalla rappresentazione intermedia, il programma target equivalente

1)Generazione di codice intermedio

2)Ottimizzazione relative al programma in esse e non al programma macchina. Tali ottimizzazioni possono essere anche più di una.

3)Generazione di Codice

Fasi di compilazione con compilatore a due fasi

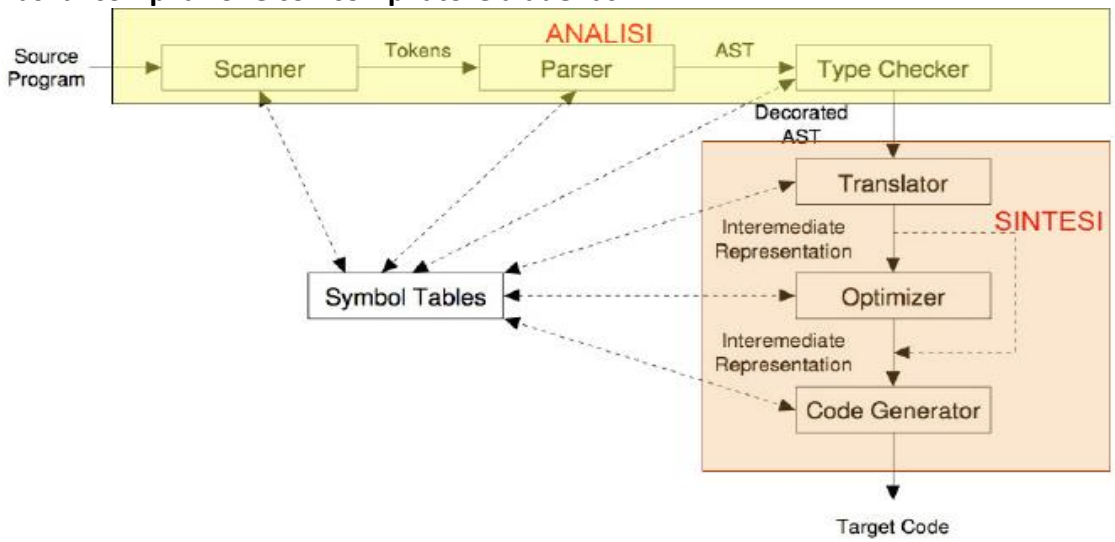

Nella fase di analisi ci sono le analisi lessicale, sintattica e semantica

1)ANALISI LESSICALE

Lo scanner legge l'istruzione e genera un token e lo passa al parser.

L'analisi lessicale (scanner) legge il programma sorgente e produce i token delle istruzioni lette.

In questa fase si scoprono errori lessicali come, per esempio, aver inserito un carattere che non doveva essere messo in quel punto (ad esempio, il simbolo del $ al posto del + per una somma) e inoltre in questa fase si eliminano informazioni non necessarie come ad esempio i commenti.

Token: descrive un insieme di caratteri che hanno lo stesso significato come ad esempio, identificatori, operatori, keywords, numeri, delimitatori. Astrazione di una certa stringa sintattica che in un linguaggio diventa standard come, ad esempio, il ++ o l'operatore if ecc. Le espressioni regolari sono usate per descrivere i token.

Gli automi a stati finiti deterministici possono essere usati per implementare un analizzatore lessicale.

Esempio analisi lessicale

Input→ newVal = oldVal + 1 - 3.2

Output→ ⟨id : newVal⟩⟨assign⟩⟨id : oldVal⟩⟨plus⟩⟨intNum : 1⟩⟨minus⟩⟨floatNum : 3.2⟩

2)ANALISI SINTATTICA

In questa fase si riconosce se un token è derivabile.

La sintassi di un linguaggio è specificata per mezzo di una grammatica context-free (CFG).

Il parser legge la sequenza di tokens e riconosce la struttura sintattica, sotto forma di un albero sintattico. Cioè riconosce quali produzioni sono state usate per generare la sequenza di token.

Un analizzatore sintattico verifica se un dato programma è derivabile dal simbolo iniziale della grammatica del suo linguaggio, cioè verifica se soddisfa le regole derivate dalle produzioni della sua CFG. In questa fase si trovano errori sintattici.

Dalla sequenza di token

⟨id : newVal⟩⟨assign⟩⟨id : oldVal⟩⟨plus⟩⟨intNum : 1⟩⟨minus⟩⟨floatNum : 3.2⟩

ottengo un parse tree dal quale posso capire le produzioni che sono state usate per generare la stringa dalla grammatica:

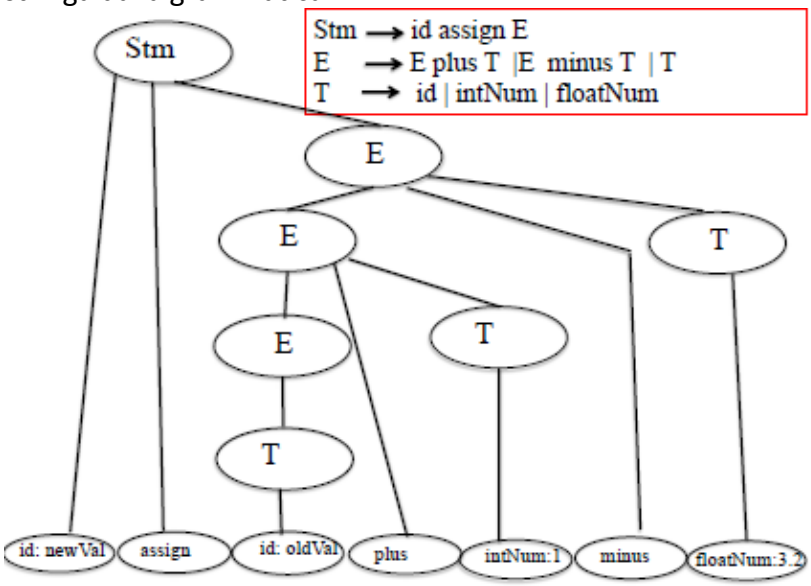

Differenze tra analisi lessicale e analisi sintattica

Quali costrutti di un programma sono riconosciuti da un analizzatore lessicale, e quali da un analizzatore sintattico?

L'analizzatore lessicale tratta solo i costrutti del linguaggio non propriamente ricorsivi.

L'analizzatore sintattico consente di trattare i costrutti del linguaggio ricorsivi.

L'analizzatore lessicale semplifica il lavoro dell'analizzatore sintattico, riconoscendo i componenti più piccoli, i tokens, del programma sorgente.

L'analizzatore sintattico lavora sui tokens riconoscendo le strutture del linguaggio.

In relazione a come viene costruito il parse-tree ci sono due differenti tecniche:

1)Top-Down

La costruzione inizia dalla radice e procede verso le foglie. Efficienti parser top-down possono facilmente essere costruiti a mano. **Parsing a discesa ricorsiva predittivo** (implementato con funzioni mutuamente ricorsive), **Parsing predittivo non a discesa risorsiva** (implementato usando l'automa pushdown).

Viene prodotta la derivazione "Leftmost" della stringa analizzata.

2)Botton-Up

La costruzione inizia dalle foglie e procede verso la radice, producendo la derivazione "Rightmost" della stringa analizzata. Di norma efficienti parser bottom-up parsers sono creati con l'ausilio di tools software. I parser Bottom-up sono anche conosciuti con il nome di parser shift-reduce.

Ci sono molte variazioni di LR Parsing: LR, SLR, LALR

3)ANALISI SEMANTICA

Controlla che le variabili siano correttamente dichiarate e che i tipi siano corretti. Queste informazioni non possono essere rappresentate con una grammatica context-free.

In questa fase, nel caso di compilatore a 2 fasi, il **type-checker** decora l'AST aggiungendogli le informazioni di tipo. Questa fase dipende dalle regole semantiche del linguaggio sorgente (è indipendente dal linguaggio target).

In Java vengono fatti ulteriori controlli durante l'analisi semantica:

→Raggiungibilità del codice

→Inizializzazione variabili prima dell'uso

→Corretto ritorno di valori da funzioni/metodi

Generazione di un codice intermedio

Un compilatore può produrre una rappresentazione esplicita del codice intermedio. Questo codice intermedio (o Intermedie Representation = IR) è indipendente dall'architettura del computer per cui si genera codice, ma può essere più o meno ad alto livello.

Esempio:

newVal = oldVal + 1 - 3.2 potrebbe essere tradotto in
ADD id2,#1,temp1
SUB temp1,#3.2,temp2
MOV temp2,id1

La generazione del codice è diretta dalla sintassi.

GENERAZIONE CODICE

La generazione del codice richiede che venga catturata la semantica dinamica (cosa fa a runtime) di un costrutto.

Per esempio, l'AST di un "while" contiene due sotto-alberi, uno per controllare l'espressione di controllo, e l'altro per il corpo del ciclo, ma non dice che un "while" ripete il body. Questo è catturato quando un AST di un ciclo while viene tradotto.

Nella IR, la nozione di verificare il valore dell'espressione di controllo e dell'esecuzione condizionale del corpo del ciclo diventa esplicito.

Codice intermedio

Il codice intermedio ha poco della macchina di destinazione. Le informazioni sulla macchina di destinazione (operazioni disponibili, indirizzamento, registri, ecc.) sono riservate per la fase finale di generazione del codice.

In semplici compilatori non ottimizzati il traduttore genera il codice di riferimento direttamente, senza utilizzare una IR.

In compilatori complessi, ad esempio GNU Compiler Collection (GCC) prima si genera un IR di alto livello (orientato al linguaggio sorgente) e poi questo viene tradotto in un IR a basso livello (orientato alla macchina). Questo approccio consente di separare le dipendenze derivanti dal sorgente e dal target.

Ottimizzazione

Il codice IR generato dal traduttore viene analizzato e trasformato in codice IR equivalente ottimizzato. Un ottimizzatore ben progettato può incrementare in modo significativo la velocità di esecuzione. Le ottimizzazioni possono essere:

-spostare o eliminare operazioni non necessarie
-rimuovere codice non raggiungibile

STATIC SINGLE ASSIGNMENT (SSA):
È un codice intermedio nel quale ogni variabile è assegnata esattamente una volta ed è definita prima del suo uso. Le variabili originali sono replicate in versioni in modo tale da tracciarne la catena di definizione ed uso.
Questo formato semplifica e migliora i risultati che si possono ottenere nella fase di ottimizzazione, semplificando le proprietà delle variabili. Per esempio:

```
y = 1
y = 2
x = y
```

il primo assegnamento è inutile, ma non è facile da capire, mentre nella sua forma SSA

```
y_1 = 1
y_2 = 2
x_1 = y_2
```

il risultato è immediato!

GENERAZIONE CODICE
Il codice IR prodotto dal traduttore viene tradotto nel codice della macchina target.
IL programma target è normalmente un codice oggetto "rilocabile" contenente codice macchina.
Questa fase fa uso di informazioni dettagliate sulla macchina target e include ottimizzazione legate alla macchina specifica quali l'allocazione dei registri e lo scheduling del codice.
Il generatore di codice può essere piuttosto complesso. Per produrre buon codice target bisogna considerare di molti casi particolari.
È possibile generare i generatori di codice in modo automatico, definendo dei template che mettano in corrispondenza le istruzioni di un IR a basso livello con quelle della macchina target.
Il compilatore GNU GCC è un compilatore fortemente ottimizzato che usa files di descrizione per più di dieci architetture PC, e di almeno due linguaggi (C and C++).

TABELLA DEI SIMBOLI
Una tabella dei simboli mantiene l'associazione fra gli identificatori e le informazioni ad essi associati (tipo, definizione, ecc.). È condivisa dalle varie fasi della compilazione. Ogni volta che un identificatore viene usato, la tabella di simboli consente di accedere alle informazioni raccolte quando è stato definito.

STRUMENTI PER LA REALIZZAZIONE DI COMPILATORI
1)Generatori di scanner: producono analizzatori lessicali (input in generale sono espressioni regolari che descrivono i token).
2)Generatori di parser: producono AST (input la grammatica). Inoltre, si possono specificare "attributi" e regole per realizzare analizzatori semantici.
3)Traduttori diretti dalla sintassi: producono collezioni di routine che visitano l'AST e generano il codice intermedio.
4)Generatori di codice: prendono regole per tradurre da IL a linguaggio macchina (soluzioni alternative selezionate con "template matching").

INTERPRETI

Ci sono due tipi diversi di interpreti che supportano l'esecuzione di programmi: interpreti di una macchina (astratta/concreta), e interpreti di un linguaggio.

Interpreti di Macchine

Simulano l'esecuzione di un programma compilato per una particolare architettura.

Java usa un interprete bytecode per simulare l'effetto del programma compilato per la Java Virtual Machine (JVM).

I programmi come SPIM simula l'esecuzione di programma MIPS su un computer non-MIPS (uso didattico).

Interpreti di Linguaggi

L'interprete del linguaggio simula l'effetto dell'esecuzione di un programma senza compilarlo in un particolare linguaggio macchina. Per l'esecuzione viene usato direttamente l'AST.

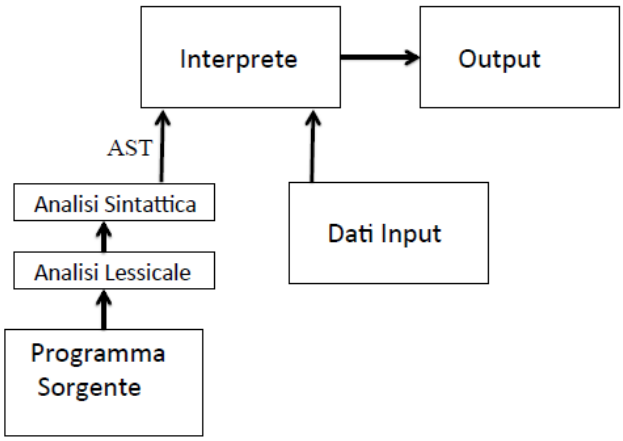

VANTAGGI

1) È possibile aggiungere codice a tempo di esecuzione.

2) È possibile generare codice a tempo di esecuzione.

3) In Python e Javascript, per esempio, qualsiasi variabile stringa può essere interpretata come una espressione ed eseguita.

4) Il tipo di una variabile può cambiare dinamicamente. I tipi vengono testati a tempo di esecuzione (non compilazione).

5) Gli interpreti supportano l'indipendenza dalla macchina. Tutte le operazioni sono eseguite nell'interprete.

SVANTAGGI

1) Non è possibile effettuare ottimizzazione del codice

2) Durante l'esecuzione il testo del programma è continuamente riesaminato, i tipi e le operazioni sono ricalcolate anche ad ogni uso.

3) Per linguaggi molto dinamici questo rappresenta un'overheads 100:1 nella velocità di esecuzione rispetto al codice compilato.

4) Per linguaggi più statici (come C o Java), il degrado della velocità è dell'ordine di 10:1.

5)Il programma sorgente spesso non è compatto come se fosse compilato. Ciò può causare una limitazione nella dimensione dei programmi eseguibili.

Il lessico

Il lessico descrive, le parole o elementi lessicali che compongono le frasi. Nei linguaggi artificiali gli elementi lessicali possono essere assegnati alle seguenti classi:

1) Parole chiave: sono particolari parole fisse che caratterizzano vari tipi di frasi o strutture. Ad es.: if, for, class.

2) Delimitatori (;) operatori (+,++,..): come i precedenti sono delle parole fisse composte di caratteri anche non alfabetici.

3) Commenti in Java sono aperti da /* e chiusi da */.

4) Classi lessicali aperte: queste comprendono un numero illimitato di elementi lessicali, che devono avere la struttura di un linguaggio regolare ossia a stati finiti. Esempi tipici sono:

→nomi o identificatori di variabili, di funzioni, o altro (classi, metodi, ...) definiti dalla espressione regolare: Id = (Lettera | _) (Lettera | Cifra | _)*

→costanti quali i numeri interi o reali o le stringhe alfanumeriche.

Analisi lessicale

La differenza fra parole chiave e classi lessicali aperte:

1)Le parole chiave non hanno altra informazione che il proprio nome,

2)Le classi lessicali denotano delle entità che hanno un valore o altre proprietà (che chiameremo attributi semantici). Ad esempio, le costanti hanno un valore.

Le classi lessicali sono delle stringhe appartenenti ad un linguaggio formale del tipo regolare. Questi linguaggi sono descritti dalle espressioni regolari e riconosciuti dagli automi a stati finiti deterministici.

L'analizzatore lessicale non deve solo verificare che una sottostringa del testo sorgente corrisponde ad un elemento lessicale valido, ma deve anche tradurla in una opportuna codifica che faciliti la successiva elaborazione da parte del traduttore o interprete.

La codifica deve contenere:

1) L'identificativo della classe lessicale cui l'elemento appartiene.

2) Gli attributi semantici (nel caso ve ne siano associati a tale classe).

Ruolo dell'analizzatore lessicale

Fornire un modo per isolare le regole di basso livello dalle strutture che costituiscono la sintassi del linguaggio.

Suddividere la frase in ingresso in elementi lessicali (detti tokens) da fornire al parser.

Eliminare gli spazi bianchi e i commenti.

Terminologia

Token: unità lessicale restituita dall'analizzatore lessicale e fornita come ingresso al parser (e.g., costante, identificatore, operatore,...)

Lessico: stringa di caratteri che rappresentano un particolare token.

Pattern: una descrizione del lessico che corrisponde al token.

Interazione tra scanner e parser

Può avvenire in due modi:

1) Lo scanner processa tutto il programma sorgente prima che inizi il parsing (tutti i token sono memorizzati in un file o tabella).

2) Lo scanner è chiamato dal parser quando c'è bisogno di un altro token, per cui non si deve memorizzare la sequenza di token.

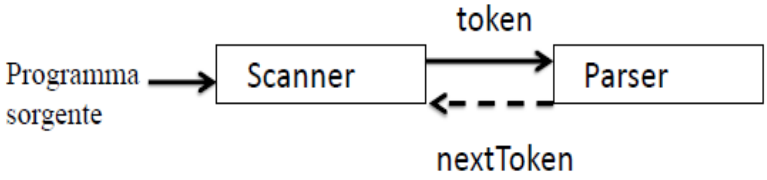

Come realizzare un analizzatore lessicale

Realizzazione procedurale: un programma ad-hoc che riconosce tutti gli elementi lessicali e produce i corrispondenti token.

→A partire dalle espressioni regolari

→A partire dall'automa a stati finiti

→A partire dalla grammatica regolare

Realizzazione tabulare interpretata: una struttura dati (tabella) rappresenta il DFA riconoscitore della grammatica G e un programma indipendente dalla grammatica G realizza il funzionamento del DFA.

Automaticamente con un generatore di Scanner, ad esempio, **JFLex** (che prende come input le espressioni regolari corrispondenti ai token).

Realizzazione procedurale

Dall'Espressione Regolare al Codice per l'analisi. Si scrive

→una sequenza per ogni concatenazione

→un test per ogni unione

→un ciclo per ogni stella di kleene

Esempio, se D=1,...,9: l'espressione regolare per i letterali interi: D (D | 0)* | 0

È riconosciuta dal seguente codice dove peekChar() restituisce il prossimo carattere senza rimuoverlo dall'input, mentre readChar() lo rimuove.

```
valTk =""
if (peekChar() in D) {
   valTk += readChar()
   while (peekChar() in D || peekChar() == '0'){
      valTk += readChar()
   }
   return Token(INT,valTk); //Pattern riconosciuto
}
if (peekChar() == '0') {
   valTk +=  readChar()
   if (peekChar() in D) ERRORE
   else  Token(INT,valTk)  //Pattern riconosciuto
}
else ERRORE
```

Riconoscere un commento di linea

L'espressione regolare, supponendo di avere Eol come simbolo di fine linea e Not che significa tutti i simboli eccetto quello specificato.

// Not (Eol) *Eol

```
if (peekChar() ==  '/') {
   readChar()
   if (peekChar() == '/') {// il secondo /
      do
         readChar()
      while ( !(peekChar() in {Eol, Eof}) )//Eof denota fine file
      if (peekChar() == Eol)
         // Processa il commento
      else ERRORE // non c'e' la fine della linea
   }
   else ERRORE //il secondo carattere non e' "/"
}
```

Dalla Grammatica Regolare al Codice per l'analisi. Si scrive:

1) Una funzione/metodo per ogni non terminale,

2) Un test per ogni alternativa,

3) Si richiama la funzione per ogni non-terminale che compare nella parte destra della produzione.

Poco usata per i linguaggi regolari perché questi vengono in genere descritti da espressioni regolari.

Come mai? Per il nostro compilatore useremo:

1) La realizzazione procedurale a partire dall'espressione regolare per l'analisi lessicale

2) La realizzazione procedurale a partire dalla grammatica per l'analisi sintattica, ciò per una grammatica context free (LL).

Realizzazione tabulare

Dall'Espressione Regolare all'Automa a Stati Finiti.

Si costruisce una tabella T tale che dato lo stato s e il carattere c, se T(s, c) = s' allora s' è lo stato successivo. Si definisce la funzione che esegue l'automa, che NON dipende dalla particolare espressione regolare.

```
valTk =""
State = StartState
while ( (peekChar() != eof) && (State non in F) {
        NextState = T[State][peekChar()]
        if(NextState == error)
                return ERRORE
        State = NextState
        valTk += readChar()
}
if (State in F) return Token(_,valTk) // il token riconosciuto
else return ERRORE // errore lessicale
```

Questa realizzazione è usata dai generatori di analizzatori lessicali. Perché?

Identificatori e parole chiave

Tutti i linguaggi utilizzano parole chiave: if, while,.....

Per queste sequenze di caratteri lo scanner deve generare token diversi da quelli degli identificatori.

Come può uno scanner decidere quando una sequenza di caratteri è un identificatore e quando è una parola chiave?

Lo scanner può procedere utilizzando il modello degli identificatori e poi cercare il token in una speciale tabella delle parole chiave. (Come potrebbe essere implementata per avere un lookup efficiente?)

Si definiscono espressioni regolari per ogni parola riservata, e per gli identificatori e si definisce una priorità fra le varie espressioni regolari.

Ad esempio

If	i f
While	w h i l e
Id	[a-zA-Z] ([a-zA-Z] | [0-9] | _)*

Il matching è con la prima espressione regolare (dall'alto in basso!). Notate comunque che dobbiamo fare il maching più lungo, cioè, se ho la stringa whiler NON mi devo fermare al riconoscimento di while, ma devo andare avanti fino a whiler e determinare che questo è un identificatore.

Conclusione dello scanning

Cosa accade quando viene raggiunta la fine del file di input?

In genere (ed è quello che faremo nel nostro compilatore) si crea uno pseudocarattere (il token EOF). (In corrispondenza al -1 ritornato da InputStream.read() viene generato il token EOF.)

Il token EOF è utile perché permette al parser di verificare che la fine logica di un programma corrisponde con la fine fisica. Molti parser richiedono l'esistenza di un tale token.

I generatori di scanner (Lex e JFlex) creano automaticamente un token EOF.

Recupero dagli errori lessicali

Una sequenza di caratteri per la quale non esiste un token valido è un errore lessicale. Gli errori lessicali non sono comuni ma devono comunque essere gestiti dallo scanner. Non è opportuno bloccare il processo di compilazione per errore lessicale. Le strategie di recupero sono:

1) Cancellare i caratteri letti fino al momento dell'errore e ricominciare le operazioni di scanning

2) Eliminare il primo carattere letto dallo scanner e riprendere la scansione in corrispondenza del carattere successivo.

Di solito, un errore lessicale è causato dalla comparsa di qualche carattere illegale, soprattutto all'inizio di un token. In questo caso i due approcci sono equivalenti.

JFLex: un generatore di scanner

Questo software, scritto interamente in Java, produce in uscita delle classi Java che implementano i metodi per effettuare l'analisi lessicale di una stringa.

La classe principale prodotta è una classe per lo Scanner (Yylex). Il costruttore ha come parametro il file che vogliamo scannerizzare. La classe contiene i metodi:

Token yylex() dove Token è la classe che vogliamo sia restituita dallo scanner che restituisce il prossimo token.

String yytext() ritorna la stringa letta per riconoscere il token.

Per funzionare, JFLex ha bisogno in ingresso un file di specifica, contenente una lista di espressioni regolari definite per il lessico. A ciascuna può essere associata una azione da compiere. Ogni volta che 'input matcha l'espressione regolate è eseguita l'azione (che in genere è la generazione di un Token, ma che per i caratteri di skip non fa niente).